

TP FINAL

Integrantes: Luis Paredes, Franco Gazzola

Collab para probar el codigo rapidamente <https://colab.research.google.com/drive/1V3YPl8S0r9cAOl3UgJiguCJ5Kz94keli?usp=sharing>

Integrantes: Luis Paredes, Franco Gazzola

Introducción

Metodo 1

Metodo 2

Longitud esperada y Cubrimiento Empirico

Cubrimiento empírico con ambos metodos siendo $n = 20, p = 0.1$

Cubrimiento empírico con ambos metodos siendo $n = 20, p = 0.5$

Cubrimiento empírico con ambos metodos siendo $n = 50, p = 0.1$

Cubrimiento empírico con ambos metodos siendo $n = 50, p = 0.5$

Cubrimiento empírico con ambos metodos siendo $n = 100, p = 0.1$

Cubrimiento empírico con ambos metodos siendo $n = 100, p = 0.5$

Conclusion

Referencias

Introducción

Generar una muestra aleatoria de una variable con distribucion Ber(p) de tamaño n (esto se realiza usando la funcion $rbinom(n,1,p)$). Para esta muestra, calcular las dos estimaciones por intervalos para p de nivel asintotico 0.95, correspondientes a los dos metodos que se mencionan a continuacion. Repetir todo este procedimiento k veces, obteniendo así k muestras independientes de tamaño n y k intervalos para cada uno de los dos métodos.

Metodo 1

Metodo de nivel asintotico donde se sustituye el valor de p en la varianza por X^-

$$\sum_{i=1}^n X_i \sim \text{Binomial}(n, p)$$

$$X_i \sim \text{Bernoulli}(p)$$

$$\mathbb{E}[X_i] = p$$

$$\text{Var}[X_i] = p \cdot (1 - p)$$

$$\text{Var}[\bar{X}] = \bar{X} \cdot (1 - \bar{X})$$

Dado que la esperanza es finita y la varianza también y considerando los x_i independientes e identicamente distribuidas por ser muestras aleatorias entonces podemos usar el teorema central de limite.

$$\frac{\sum_{i=1}^n X_i - n \cdot \mathbb{E}[X_i]}{\sqrt{n \cdot \text{Var}[X_i]}} = \frac{\sum_{i=1}^n X_i - n \cdot p}{\sqrt{n \cdot \bar{X} \cdot (1 - \bar{X})}} \sim \text{Normal}(0, 1)$$

Como conozco la distribución y relaciona al parámetro desconocido, la uso como pivote.

$$U = \frac{\sum_{i=1}^n X_i - n \cdot p}{\sqrt{n \cdot \bar{X} \cdot (1 - \bar{X})}}$$

Entonces

$$P(a < U < b) = 1 - \alpha$$

Siendo U normal estándar busco el intervalo de confianza más corto. Aprovechando la simetría de la normal nos quedamos con

$$\mathbb{P}(-z_{1-\alpha/2} \leq U \leq z_{1-\alpha/2}) = 1 - \alpha$$

reemplazando y despejo el parámetro desconocido

$$\mathbb{P}(-z_{1-\alpha/2} \leq \frac{\sum_{i=1}^n X_i - n \cdot p}{\sqrt{n \cdot \bar{X} \cdot (1 - \bar{X})}} \leq z_{1-\alpha/2}) = 1 - \alpha$$

$$\mathbb{P}(-z_{1-\alpha/2} \cdot \sqrt{n \cdot \bar{X} \cdot (1 - \bar{X})} \leq \sum_{i=1}^n X_i - n \cdot p \leq z_{1-\alpha/2} \cdot \sqrt{n \cdot \bar{X} \cdot (1 - \bar{X})}) = 1 - \alpha$$

$$\mathbb{P}\left(\frac{\sum_{i=1}^n X_i - z_{1-\alpha/2} \cdot \sqrt{n \cdot \bar{X} \cdot (1 - \bar{X})}}{n} \leq p \leq \frac{\sum_{i=1}^n X_i + z_{1-\alpha/2} \cdot \sqrt{n \cdot \bar{X} \cdot (1 - \bar{X})}}{n}\right) = 1 - \alpha$$

Entonces el intervalo de confianza nos queda

$$IC(\underline{X}) = \left(\frac{\sum_{i=1}^n X_i - z_{1-\alpha/2} \cdot \sqrt{n \bar{x} (1 - \bar{x})}}{n}, \frac{\sum_{i=1}^n X_i + z_{1-\alpha/2} \cdot \sqrt{n \bar{x} (1 - \bar{x})}}{n} \right)$$

Metodo 2

Método de nivel asintótico cuando no se sustituye a p y se calcula los extremos del intervalo.

Presentemos el teorema del capítulo 9 visto en clase

Bajo ciertas condiciones muy generales, sea $\Theta(\underline{X})$ un EMV de Θ consistente y sea $q(\theta)$ derivable con $\frac{d}{d\theta} q(\theta) \neq 0$ pa
Entonces vale que $\sqrt{n} \cdot \sqrt{\mathbb{I}(\theta)} \cdot (\hat{\Theta}_n - \theta) \sim N(0, 1)$

Usando de referencia el **ejemplo 8** del capítulo **PARAMETRIC INTERVAL ESTIMATION** del libro Alexander Mood ([3]) y tomando como pivote el resultado del teorema anterior desarrollamos:

Sabiendo que para una muestra aleatoria $X_1, \dots, X_n \stackrel{iid}{\sim} Ber(p)$, $p \in (0, 1)$

$$\hat{p}_{EMV} = \bar{X} = \frac{\sum_{i=0}^n X_i}{n}$$

$$I(p) = -E\left[\frac{d^2}{dp^2} \ln(f_p(x))\right] = \frac{1}{p \cdot (1-p)}$$

entonces el pivote U es

$$U = \sqrt{n} \cdot \sqrt{\frac{1}{p \cdot (1-p)}} \cdot (\bar{X} - p) \sim N(0, 1)$$

De nuevo, como U es normal estándar busco el intervalo de confianza más corto aprovechando la simetría de la normal y reemplazo el pivote obtenemos

$$\mathbb{P}\left(-z_{1-\alpha/2} \leq \frac{\bar{X} - p}{\sqrt{\frac{p \cdot (1-p)}{n}}} \leq z_{1-\alpha/2}\right) = 1 - \alpha$$

Al despejar la variable desconocida (p) el intervalo de confianza nos queda

$$IC(\underline{X}) = \left(\frac{2n\hat{p} + z^2 - z\sqrt{4n\hat{p} + z^2 - 4n\hat{p}^2}}{2(n+z^2)}, \frac{2n\hat{p} + z^2 + z\sqrt{4n\hat{p} + z^2 - 4n\hat{p}^2}}{2(n+z^2)} \right)$$

Longitud esperada y Cubrimiento Empírico

Para el método 1 y el método 2 realizando una única vez el experimento obtenemos los siguientes resultados:

n	p	metodo	ext_izq	ext_der	cubrimiento_emp	long_estimada
20	0.1	1	-0.03147838	0.2314784	1	0.2629568
20	0.1	2	0.02786648	0.3010336	1	0.2731672
20	0.5	1	0.33196777	0.7680322	1	0.4360645
20	0.5	2	0.34208534	0.7418021	1	0.3997168
50	0.1	1	0.02992691	0.2100731	1	0.1801462
50	0.1	2	0.05617600	0.2380482	1	0.1818722
50	0.5	1	0.44319508	0.7168049	1	0.2736098
50	0.5	2	0.44233442	0.7062500	1	0.2639155
100	0.1	1	0.05630871	0.1836913	1	0.1273826
100	0.1	2	0.06999406	0.1981210	1	0.1281269
100	0.5	1	0.47296694	0.6670331	1	0.1940661
100	0.5	2	0.47215390	0.6626670	1	0.1905131

Para cada experimento se obtienen k muestras aleatorias y para cada una se calcula si el intervalo de confianza contiene el valor real de p .

De todas las k muestras aleatorias calculamos la proporción de veces que el intervalo contenía al verdadero parámetro.


Observamos que cada vez que se volvía a correr el código la proporción cambiaba ligeramente por ser los intervalos de confianza dependientes de la muestra aleatoria.


Para entender bien la proporción real se corrió el experimento k veces para cada combinación de n y p para observar hacia qué valores tiende la proporción real y se tomó la media como valor representativo.

n	p	metodo	cubrimiento_emp	long_estimada
20	0.1	1	0.8761262	0.2342990
20	0.1	2	0.9568030	0.2632072
20	0.5	1	0.9588445	0.4268606
20	0.5	2	0.9588445	0.3927088
50	0.1	1	0.8786607	0.1610425
50	0.1	2	0.9703173	0.1664771
50	0.5	1	0.9351765	0.2743654
50	0.5	2	0.9351765	0.2645931
100	0.1	1	0.9325300	0.1158818
100	0.1	2	0.9365942	0.1176802
100	0.5	1	0.9434352	0.1950103
100	0.5	2	0.9434352	0.1914054


En los siguientes gráficos la línea roja representa el promedio luego de haber realizado k veces cada experimento.



Cubrimiento empírico con ambos métodos siendo $n = 20$, $p = 0.1$








Cubrimiento empirico con ambos metodos siendo n = 20, p = 0.5







Cubrimiento empírico con ambos métodos siendo $n = 50$, $p = 0.1$







Cubrimiento empirico con ambos metodos siendo $n = 50$, $p = 0.5$







Cubrimiento empirico con ambos metodos siendo $n = 100$, $p = 0.1$





Cubrimiento empirico con ambos metodos siendo $n = 100$, $p = 0.5$





Conclusion

Observamos que al ir aumentando la muestra vemos que ambos metodos van mejorando sistemáticamente su proporción de cubrimiento empírico y su intervalo de confianza se va achicando.

Notamos que ambos métodos tienen la misma media para el cubrimiento empírico cuando $p=0.5$ aunque la longitud sea distinta (por lo general el método 2 tiene una longitud más corta) y cuando $p=0.1$ la media para el cubrimiento empírico varía entre métodos.

Vemos que con una muestra pequeña ($n=20$) el método 2 tiene un cubrimiento empírico mejor que el método 1.

Esto se debe a que para $p=0.1$ la probabilidad de que salga 1 es baja entonces para una muestra pequeña es posible que salgan pocos 1 y el modelo va a pensar que p es cero y como también arrastra error de aproximación (varianza = media de la muestra) entonces el error de cubrimiento empírico va aumentando.

Referencias

1. [Apuntes de Estadística - Ing. Jemina M. García - 2020](#)
2. [Probabilidad y Estadística Elementales para Estudiantes de Ciencias](#)
3. [Introduction to the Theory of Statistics \(Pag 394-396\) - Alexander Mood](#)